AI Service, Mini Project 설계

AI3기_3반_3076 배수정, 3080 안가은

Goal

- HBM4, PIM, CXL 관련 최신 공개 신호를 수집/정규화하고, 경쟁사별 기술 성숙도와 위협 수준을 TRL 기반으로 추정하여, R&D 담당자가 바로 의사결정에 활용할 수 있는 기술 전략 보고서 생성
- **Desired Outcome**
  - R&D 담당자가
    - 왜 특정 기술에 집중해야 하는지와 그 이유
    - 추가 조사 필요 영역과 공개 정보만으로는 판단이 어려운 영역이 명확히 구분되는지
    - 경쟁사의 현재 기술 수준(TRL)과 위협 수준이 구체적 근거와 함께 제공되는지
    - 고객사인 SK hynix가 의사결정을 내리는데 도움이 되는 전문적인 인사이트가 확보되는지

Success Criteria

- **결과 품질 기준**
  - 근거성 : 모든 주요 주장에는 최소 1개 이상의 명시적 출처 포함
  - 완결성 : 정해진 목차를 모두 포함하고, RAG 문서 내 핵심 내용을 누락 없이 전문적 근거로 활용
  - 일관성 : 경쟁사 비교 결과에서 내부 모순 없이 일관된 평가 기준 적용
- **업무적 제약 조건**
  - 톤앤매너: R&D 전문가용 전문 용어 및 객관적 어조를 사용
  - 공개된 정보만 활용하여 비공개/추정 정보는 사용하지 않음
  - TRL 4-6 구간은 확정이 아닌 추정으로 명시

    - 비교 범위는 Samsung, Micron으로 제한하며 부족한 경우 '부족함'으로 명확히 표기
    - 결과는 정해진 보고서 템플릿 구조로 출력
- **서비스 기준**
    - 검색 실패 시 무한 반복하지 않고 최대 재시도 횟수 내 종료함
    - 쿼리 입력 후 보고서 생성 완료까지의 소요 시간 10분 이내
    - 근거가 부족할 경우, 임의 생성 없이 '판단 불가' 또는 '정보 부족'으로 응답
    - 같은/유사 입력에 대해 일관된 분석 구조와 품질 수준 유지
    - 반복 실행 시 결과 품질 변동이 허용 범위를 넘지 않도록 안정성 유지
    - 강점(긍정)과 한계(부정) 관점의 출처를 최소 1개씩 교차 확보함으로써, 웹서치 확증편향 완화

Task

1. 분석 범위 및 쿼리 정의
2. 관련 근거 수집 및 신뢰도 판단
3. 질문-근거 매핑
4. 분석 결과 생성 및 보고서 초안 작성
5. 내부 정책 위반 여부 체크

Control Strategy

1. Loop Strategy & Conditional Branch

Loop A : 근거 품질 개선 루프

- 수집된 근거가 긍정/부정 한쪽으로 편향되어 교차 검증이 불가능한 경우
- 사용자의 질문과 수집된 근거가 매칭되지 않는 경우

⇒ 부족한 관점이나 키워드를 명시하여 Web Search / RAG Agent로 재진입

Loop B : 정책 준수 개선 루프

- TRL 4-6 구간 평가 시 추정이라는 명시적 표현이 누락된 경우

- 톤앤매너를 어기고, Hallucination 문장이 포함된 경우
- 지정된 목차 템플릿 구조를 따르지 않은 경우

⇒ 위반된 정책을 피드백으로 작성하여 Draft Generation Agent로 재진입

---

2. Retry & Termination Policy

무한 반복을 방지하고 서비스 기준(Latency 10분 이내)을 만족시키기 위한 명확한 종료 조건 설정

- 최대 재시도 : Loop A와 Loop B의 재진입은 각각 최대 2회로 제한
- Fallback
  - 최대 2회 재검색(Loop A) 후에도 적합한 교차 근거를 찾지 못한 경우, 임의 창작을 강제로 차단
  - 해당 항목에 대해 '정보 부족으로 인한 판단 불가' 또는 '추정 보류' 상태로 명시하고, 임의 추론 없이 다음 단계로 진행
- 최종 종료 : 무사히 통과하거나 최대 재시도 후 안전하게 Fallback 처리된 초안은, Formatting Node를 통해 최종 PDF 문서로 생성되며 워크플로우 종료

Agent

- ***Web search Agent :*** 웹 검색을 통해 근거 수집
- ***RAG Agent :*** 문서를 기반으로 기술적 근거를 추출
- ***Draft Generation Agent :*** 초안 보고서 작성

```
flowchart TD
  U[User Query] --> S[Supervisor]

  S -->|문서 검색 요청| R[RAG Agent]
  S -->|경쟁사 정보 검색 요청| W[Web Search Agent]

  R -->|문서 기반 Context 반환| S
  W -->|웹 기반 Context 반환| S
```

```
    S -->|통합 Context 전달| D[Draft Generation Agent]

    D -->|초안 검토 요청| S
    S -->|기준 미충족 시 수정 요청| D

    S -->|검증 OK: 문서화 요청| F[Formatting Node]
    F -->|문서 생성 결과 반환| S
    S -->|최종 승인| END[END]
```

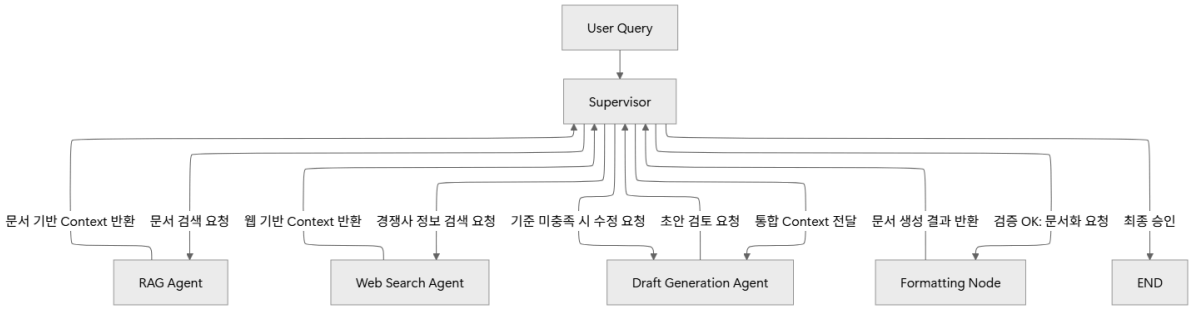

STATE

1. Master State

LangGraph 파이프라인에서 굴러가는 최종적인 마스터 State 구조

```
from typing import TypedDict, Annotated, List
from langchain_core.messages import BaseMessage
from langgraph.graph.message import add_messages

class AgenticWorkflowState(TypedDict):
    global_info: "GlobalState"          # 전체 공유 및 대화 기록
    supervisor_ctrl: "SupervisorState"  # Supervisor 통제 수첩
    retrieval_data: "RetrievalState"    # 검색된 날것의 데이터
모음
    draft_work: "DraftState"            # 초안 작성 공간
```

2. 세부 State

A. Global State

```
class GlobalState(TypedDict):
    messages: Annotated[List[BaseMessage], add_messages]
    # 사용자의 초기 질문, 에이전트의 응답, Tool 검색 결과가 모두 누적
됨
    # LLM이 이전 검색의 실패 맥락을 기억하고 다음 행동을 교정할 수 있
게 함

    query: str                  # 사용자의 요청 사항
    final_report: str           # Formatting Node를 거친 최종
보고서 텍스트
    workflow_status: str        # 현재 진행 상태 ("STARTED", "I
N_REVISION", "COMPLETED" 등)
```

B. Supervisor State

```
class SupervisorState(TypedDict):
    next_agent: str             # 다음에 호출할 하위 에이전트 지정
    revision_count: int         # 현재 반려/재시도 횟수 (Max Ite
ration 제어 및 무한 루프 방지)
    missing_info_log: List[str] # 검색 실패 시 '판단 불가'로 확정
한 기술 항목 (Hallucination 차단)
```

C. Retrieval State

```
class RetrievalState(TypedDict):
    rag_raw_chunks: List[str]   # 문서에서 추출한 Context와 출처
    web_raw_results: List[str]  # 웹 서치로 수집한 경쟁사 동향
```

D. Draft State

```
class DraftState(TypedDict):
    current_draft: str          # 현재 작성된(또는 수정 중인) 보
```

```
고서 초안
    trl_justification: str      # TRL 4~6 구간을 '추정'으로 판단
한 이유.
```

Distributed vs Supervisor

- **Supervisor** 구조 선택
- 선택의 이유: Supervisor는 검증-수정-보고서 생성의 흐름을 중앙에서 제어하는 구조인데, 이번 프로젝트에서는 근거 수집 → 검증 → 수정 → 최종 보고서 생성의 흐름을 안정적으로 관리가 중요하게 여겨지기 때문에 선택하였다.

  반면, Distributed 구조에서는 각 에이전트가 독립적으로 산출물을 생성하기 때문에, 보고서 초안이 검증 없이 바로 완성될 경우 근거 충돌, 중복 주장, 과도한 확신 등의 품질 문제가 생기기 때문에 Supervisor를 선택하였다.

Retrieve

1. OpenSource Embedding

- 후보군
  - BGE-M3
  - Text-embedding-3
- 선정 기준
  - 다국어 처리 능력
  - 도메인 적합성
  - Retrieval 확장성
  - 문서 처리 능력

2. Retrieval Technique

- 후보군
  - BM25

    - MMR
    - Score Threshold
    - Hybird
- 선정 기준
    - 도메인 적합성
    - 정보 다양성
    - 검색 품질
    - 키워드 민감도 vs 의미 이해

Web Search 설계 근거

이번 프로젝트에서는 웹 검색 과정에서 발생할 수 있는 확증 편향을 완화하도록 Web Search Agent를 설계하였다.

최신 반도체 기술 정보는 공개 자료의 양과 방향이 불균형할 수 있고, 검색어 설계에 따라 특정 기업이나 기술에 유리한 정보만 수집될 가능성이 있기 때문이다. 이를 줄이기 위해 검색 단계에서 긍정·부정 등 분리한 다중 쿼리 전략을 적용하고, 출처 유형을 다양화하여 근거를 수집하도록 하였다. 또한 검색 결과가 특정 방향으로 치우친 경우에는 Supervisor가 재검색 또는 추가 근거 수집을 지시하도록 하여, 최종 보고서가 한쪽 주장에 편향되지 않도록 설계하였다.

보고서 목차

SUMMARY

- 분석 대상 기술(HBM, PIM, CXL)의 현재 위치 요약
- 경쟁사별 기술 성숙도(TRL) 및 위협 수준 비교
- R&D 관점에서의 우선 대응 방향 핵심 제시

1. 분석 배경

1.1. 분석 목적

- 왜 해당 기술을 지금 분석해야 하는가
- 시장 및 기술 환경 변화와의 연관성

1.2. 분석 범위 및 기준

- 분석 대상 기술 및 경쟁사 범위 정의
- 활용 데이터 범위 (내부정보 노출 금지)

1.3. TRL 기반 평가 기준 정의

- TRL 9단계 구조 요약
- 본 보고서에서의 TRL 해석 기준

2. 분석 대상 기술 현황

2.1. HBM 기술 현황

- 기술 개요 및 핵심 특징
- 현재 개발 단계 및 방향성

2.2. PIM 기술 현황

- 기술 개요 및 핵심 특징
- 현재 개발 단계 및 방향성

2.3. CXL 기술 현황

- 기술 개요 및 핵심 특징
- 현재 개발 단계 및 방향성

3. 경쟁사 동향 분석

3.1. 경쟁사별 기술 개발 방향

- Samsung
- Micronss

3.2. TRL 기반 기술 성숙도 비교

- 기술별 TRL 수준 비교
- 경쟁사별 상대적 위치

3.3. 위협 수준 평가

- 기술 완성도와 시장 적용 가능성 평가

- 위협 수준 (High / Medium / Low)

4. 전략적 시사점

4.1. 기술별 전략적 중요도

- 어떤 기술에 집중할지
- 우선순위 판단 근거

4.2. 경쟁 대응 방향

- 경쟁사 대비 대응 전략 제안

4.3. 한계

- TRL 4-6 구간의 추정 한계

REFERENCE

- 보고서 작성 시 활용한 자료 목록